

시계열 데이터 특성에 따른 TSFM의 Zero-Shot-Few-Shot 성능 전환점 분석

가제: *When Does Fine-Tuning Beat Zero-Shot Forecasting? Data-Characteristic-Dependent Crossover Points of Time-Series Foundation Models*

기준 논문: Li et al., *TSFM-Bench: A Comprehensive and Unified Benchmark of Foundation Models for Time Series Forecasting*, KDD 2025 ([논문](#), [공식 코드](#)). 데이터 통계는 첨부 PDF 4쪽 표 3, 설명은 11쪽 부록 B.1, 퓨샷 대상은 7쪽 표 6 참조.

연구 질문과 핵심 개념

새로운 시계열을 예측할 때 사전학습 모델을 그대로 쓰는 **제로샷**과, 대상 데이터 일부로 추가 학습하는 **퓨샷 파인튜닝** 중 어느 쪽이 좋은가? 필요한 학습 데이터의 양이 달라질 때 두 방법의 성능 순위가 뒤집히는 **전환점**은 데이터 특성과 모델에 따라 어떻게 달라지는가?

제로샷은 대상 데이터로 모델 파라미터를 업데이트하지 않는 평가다. 다만 입력 구간의 관측값은 예측에 사용한다. 퓨샷은 대상 데이터의 시간상 앞쪽에 놓인 훈련 구간 중 일부로 모델을 업데이트한 뒤 **동일한 테스트 구간**에서 평가한다. 예컨대 테스트 MAE가 제로샷 0.40이고 1%, 2%, 5%, 10% 학습에서 각각 0.43, 0.41, 0.38, 0.37이면 관측한 최초 역전 구간은 **2% 초과~5% 이하**다. 이를 '3%가 정확한 전환점'이라고 말할 수는 없다.

단순한 역전과 실질적인 개선을 구분한다. 동일 테스트 구간에서 $\text{개선률}(r) = [\text{제로샷 손실} - \text{퓨샷 손실}(r)] / \text{제로샷 손실}$ 을 계산하고, 복수 시드와 불확실성 분석에서 개선이 안정적인 첫 학습량을 **실용 전환점**으로 정의한다. 끝까지 개선하지 않는 사례는 '전환점 미관측(상한까지만 확인)'으로 기록하고, 여러 번 순위가 뒤집히면 최초 역전과 지속적인 역전을 따로 기록한다. 학습 시간·비용을 포함한 전환점은 별도의 분석이다.

기준 논문은 제로샷·5% 퓨샷·풀샷을 비교하고 일곱 가지 데이터 특성을 조사한다. 이 연구의 추가 기여는 **여러 학습량을 촘촘히 측정**해 데이터 특성과 모델별 전환 구간 및 '파인튜닝이 오히려 악화하는 구간'을 추정하는 데 있다. 결과는 이 21개 벤치마크의 범위에서 해석하며, 같은 산업의 새로운 사업장에도 임계값이 그대로 적용된다고 주장하지 않는다.

연구에 사용할 14개 데이터셋과 확보 경로

한꺼번에 받기: 저자 공식 저장소의 전처리 데이터 압축파일([dataset.zip](#)). 저장소 README의 데이터 준비 절에서 링크한 파일이다. 다운로드한 뒤 압축을 풀어 저장소의 [dataset/](#) 에 배치한다. 이 환경에서는 압축파일 내부와 연구 대상 14개 파일의 포함 여부를 직접 확인하지 못했다. 따라서 아래는 **논문에서 제로샷과 5% 퓨샷을 모두 평가한 14개 목록 및 공식 묶음 다운로드 경로**이며 개별 파일 확보·형식 검증 완료 목록은 아니다. 논문 표의 표기를 그대로 유지했다([CzeLan](#)); 본문 일부에는 [CzeLan](#) 표기가 등장한다.

번호	데이터셋	분야·측정 대상	변수 수	시점 수	간격	분할 비율 (훈련:검증:테스트)
1	ETTh1	전력 변압기	7	14,400	1시간	6:2:2
2	ETTh2	전력 변압기	7	14,400	1시간	6:2:2
3	ETTm1	전력 변압기	7	57,600	15분	6:2:2
4	ETTm2	전력 변압기	7	57,600	15분	6:2:2
5	Electricity	전력 소비	321	26,304	1시간	7:1:2
6	Traffic	도로 점유율	862	17,544	1시간	7:1:2
7	PEMS08	교통량	170	17,856	5분	6:2:2
8	Solar	태양광 발전	137	52,560	10분	6:2:2
9	Wind	풍력 발전	7	48,673	15분	7:1:2
10	Weather	기상 관측	21	52,696	10분	7:1:2
11	AQShunyi	대기질	11	35,064	1시간	7:1:2

번호	데이터셋	분야·측정 대상	변수 수	시점 수	간격	분할 비율 (훈련: 검증:테스트)
12	Exchange	환율	8	7,588	1일	7:1:2
13	ZafNoo	수액 흐름·환경	11	19,225	30분	7:1:2
14	CzeLan	수액 흐름·환경	11	19,934	30분	7:1:2

선정 근거: 첨부 논문은 21개 모두의 제로샷을 평가했지만, 훈련 샘플 확보 조건으로 5% 퓨샷 표 6은 이 14개 장기 예측 데이터셋만 담는다. 따라서 동일한 제로샷·퓨샷 출발점을 재현한 뒤 학습량을 확장할 수 있다. 데이터셋별 1%의 절대 원도 수는 다르므로 두 값을 함께 기록한다. 분야가 다양해도 데이터셋 간 독립성은 보장되지 않는다. ETT 네 개와 수액 흐름 두 개처럼 유사 계열이 존재하므로 특성-전환점 관계를 분석할 때 계열별 민감도 분석을 병행한다.

사전학습 모델 6개

아래 여섯 모델은 첨부 논문의 **제로샷 표 5와 5% 퓨샷 표 6에 모두 결과가 있는** 시계열 사전학습 모델이다. 구현과 체크포인트는 **TSFM-Bench** 저장소의 모델별 스크립트와 README를 우선 사용하고 **논문에서 평가한 동일 버전·체크포인트를 고정**한다. 최신 버전을 바꾸면 원 논문과 직접 비교할 수 없다.

모델	선택 이유	사전학습 유형 (논문 분류)	실행 시 확인할 점
Chronos	널리 쓰이는 확률 예측 계열; 구조 대비	하이브리드	샘플 예측에서 점 예측을 만드는 방식과 시드 고정
Moirai	다변량·다양한 채널 구성 비교	복원 기반	채널 수와 공변량 설정, 모델 크기 고정
TTM	작은 모델의 파인튜닝 효율 비교	직접 예측	입력 길이와 예측 길이에 맞는 체크포인트 확인
Timer	자기회귀 계열 및 원 논문의 강한 결과 비교	자기회귀	큰 모델의 GPU 시간과 길이별 설정 확인
UniTS	통합 시계열 표현 및 채널 간 상관성 비교	복원 기반	타깃 차원과 데이터셋별 설정 확인
MOMENT	복원 기반 모델의 다른 설계 비교	복원 기반	forecasting head 및 파인튜닝 가능 파라미터 확인

우선순위: **TTM** → **Chronos** → **Moirai**로 파일·평가 파이프라인을 먼저 검증한 후 Timer, UniTS, MOMENT를 확장한다. 6개 모두 × 14개 × 다수 학습 비율 × 4개 예측 길이 × 여러 시드는 상당한 계산량이므로, 먼저 4개 데이터셋에 3개 모델로 파일럿을 실시하고, 14개와 6개 모델로 단계적으로 확대한다. TimesFM도 유명하고 제로샷·5% 퓨샷 결과가 있지만 첨부 논문의 풀샷 표에는 결과가 없어, 여기서는 연구의 동일 설정 확장성을 고려해 제외했다. 그 대신 TimesFM을 넣고 싶다면 논문 버전의 파인튜닝 구현과 제한 사항부터 재현해야 한다.

실험 설계 초안

- 동일 조건 구성:** 공식 전처리 파일의 행·열·결측·시간 열을 논문 표 3과 대조하고 시간순 분할을 재현한다. 학습 구간에서만 정규화 통계를 얻는다. 사전학습 자료와 평가 데이터의 중복 가능성도 확인해, 제로샷을 '미관측 도메인 일반화'로 과장하지 않는다.
- 베이스라인 재현:** 논문의 14개 데이터에 대한 제로샷 및 5% 퓨샷 수치를 동일 체크포인트·예측 길이·평가 방식에서 먼저 재현한다. 논문은 장기 예측 길이 96/192/336/720 및 입력 길이 96/336/512를, 입력 길이 중 최선의 결과를 보고한다(PDF 5~6쪽). 입력 길이를 사후에 테스트 성능으로 선택하는 문제를 피하려면 사전 고정하거나 검증 구간에서만 선택한다.
- 학습량 스윙:** 제로샷 0%, 그다음 0.5/1/2/5/10/20/50/100%를 후보로 두되 **절대 훈련 원도 수**를 함께 기록한다. 논문 기본 설정은 5%의 균일한 원도 샘플링과 전체 검증 구간 사용이다(PDF 6쪽). 본 연구에서는 검증 데이터까지 학습에 쓰는 것으로 오해되지 않게 별도 기록하고, 검증 구간 크기의 영향도 따로 분석한다. 예측 길이별로 유효한 훈련 원도 수를 먼저 세고 부족한 비율은 제외한다.
- 공정한 파인튜닝:** 각 비율의 샘플 추출 방식, 시드, 업데이트 횟수, 조기 종료 및 하이퍼파라미터 탐색 예산을 동일하게 기록한다. 데이터량을 늘릴수록 최적화 횟수도 늘릴지, 동일 횟수로 제한할지 선택해 두 프로토콜을 구분한다. 3~5개의 시드와 MAE·MSE를 보고하며 가능하면 추론 및 학습 시간도 측정한다.

5. **전환점 및 특성:** 7가지 특성(계절성, 추세, 정상성, 변화·전환, 분포 이동, 채널 상관, 비정규성)은 공식 논문 부록 B.2의 정의에 따라 **훈련 구간에서만** 계산한다. 변수 수, 훈련 시점 수, 시간 간격, 예측 길이도 보조 변수로 둔다. 데이터셋·모델·예측 길이별 전환 구간과 미관측 사례를 보고하고, 14개 표본으로 복잡한 예측 규칙을 학습하기보다 설명적 관계와 불확실성을 중심으로 분석한다.

핵심 도표: x축에 실제 학습 원도 수와 비율, y축에 '제로샷 대비 테스트 오차 개선률'을 그린 모델별 성능곡선. 0선을 넘는 최초 구간을 표시하고, 각 데이터의 특성과 전환 구간을 별도 표로 정리한다. 같은 산업 내 독립 사업장이 거의 없으므로 도메인별 인과 설명이나 산업 전체의 임계값 주장은 피한다.

연구 범위에서 제외한 원 논문 데이터셋 7개

FRED-MD(거시경제·728시점), ILLI(독감·966시점), Covid-19(코로나19·1,392시점), NASDAQ(주식·1,244시점), NYSE(주식·1,243시점), NN5(ATM·791시점), Wike2000(웹 조회·792시점). 원 논문 표 3에는 포함되지만 5% 퓨샷 표 6에는 결과가 없어 본 연구의 전환점 분석에서는 제외한다. 14개 결과를 확인한 후 별도 후속 연구 대상으로 삼을 수 있다.